

Universidad Tecnológica de Ciudad Juárez



U2 Resultado de Aprendizaje

Extracción de Datos

IDSW21

Contreras Salomón Luis Pablo

Fecha de entrega: 29 de junio de 2026

Índice

Introducción.....	3
Esquema de data warehouse.....	4
Tabla de Hechos	4
Tabla Dimensión Estudiante	4
Tabla Dimensión Materia	4
Tabla Dimensión Docente	5
Tabla Dimensión Programa.....	5
Tabla Dimensión Periodo	5
Tipos y fuentes de datos	6
Técnicas de limpieza de datos	7
Parámetros de configuración del data warehouse.	8
Conclusión.....	10

Introducción

En este proyecto se desarrolló un Data Warehouse para analizar el desempeño académico de los estudiantes y facilitar la toma de decisiones en una institución educativa. Para ello, se realizó la limpieza y organización de los datos, se diseñó un esquema con tablas de hechos y dimensiones, y se implementó un dashboard en Power BI. Se realizaron todos estos pasos para transformar datos dispersos en información clara y útil, facilitando el análisis de indicadores como el promedio de calificaciones, el desempeño docente, las diferencias entre municipios y la relación entre asistencia y rendimiento académico.

Esquema de data warehouse.

Primero se tuvo que identificar los datos proporcionados, en este caso se dividieron los datos en forma de tablas en correspondencia a sus características.

Tabla de Hechos

DesempenoAcademico

Campo	Descripción
id_estudiante	FK Estudiante
id_materia	FK Materia
id_docente	FK Docente
id_programa	FK Programa
id_periodo	FK Periodo
calificacion_final	Medida

Tabla Dimensión Estudiante

Campo
id_estudiante
nombre_estudiante
sexo
edad
municipio
bachillerato_procedencia

Tabla Dimensión Materia

Campo
id_materia
nombre_materia
area_conocimiento
tipo_materia

Tabla Dimensión Docente

Campo
id_docente
nombre_docente
formacion_docente
antiguedad_docente

Tabla Dimensión Programa

Campo
Id_programa
nombre_programa
nivel_programa
modalidad_programa

Tabla Dimensión Periodo

Campo
id_periodo
anio
semestre
fecha_inicio
fecha_fin

Tipos y fuentes de datos

Los datos que se utilizan para identificar las tablas, y sacar resultados para un análisis se extraen de un dataset entregado en un archivo CSV llamado:

RA Dataset datos_estudiantes.csv

La información de este archivo incluye los datos de una institución sobre sus estudiantes y el sistema académico institucional.

La principal información que se identificó en el archivo proporcionado fue la siguiente:

Fuente	Datos obtenidos
Estudiantes	Información personal y municipio
Materias	Nombre, área y tipo
Docentes	Nombre, formación y antigüedad
Programas	Carrera, modalidad y nivel
Periodos	Año, semestre y fechas
Evaluaciones	Calificación final y asistencia

Técnicas de limpieza de datos

El dataset que se nos presento tenía muchos datos duplicados, errores duplicados, valores no identificados y falta de conversión de tipos de datos. Como se muestra en el siguiente ejemplo:

id_estudiante	nombre_estudiante	sexo	edad	municipio	bachillerato_procedencia	id_materia	nombre_materia	area_conocimiento	tipo_materia	id_docente	nombre_docente	formacion_docente	antiguedad_docente	id_programa	nombre_programa	nivel_programa	modalidad_programa
E001	Ana PÁdrez	F	19	Chihuahua	CETis 22	M101	Matemáticas Discretas	Matemáticas	Obligatoria	D001	Mario LAópez	Maestría	10	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado
E002	Carlos Ruiz	M	20	Juárez	CBTis 128	M102	Programación I	Computación	Obligatoria	D002	Laura GÓmez	Licenciatura	6	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado
E003	Diana RÍos	F	21	Delicias	COBACH 3	M101	Matemáticas Discretas	Matemáticas	Obligatoria	D001	Mario LAópez	Maestría	10	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado
E001	Ana PÁdrez	F	19	Chihuahua	CETis 22	M102	Programación I	Computación	Obligatoria	D002	Laura GÓmez	Licenciatura	6	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado
E004	Erick Salas	M	22	Parral	CONALEP	M103	Física I	Ciencias	Obligatoria	D003	Juan Mendoza	Doctorado	15	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado

Para tener una mejor organización de los datos se realizaron las siguientes actividades de preparación de datos:

- Eliminación de registros duplicados.
- Corrección de errores ortográficos.
- Conversión de tipos de datos (fechas y números).
- Separación de tablas de dimensiones.
- Creación de la columna calculada **Estado_Aprobación**, donde:

Aprobado: calificación ≥ 70 .


Reprobado: calificación < 70 .

id_estudiante	nombre_estudiante	sexo	edad	municipio	bachillerato_procedencia	id_materia	nombre_materia	area_conocimiento	tipo_materia	id_docente	nombre_docente	formacion_docente	antiguedad_docente	id_programa	nombre_programa	nivel_programa	modalidad_programa	id_perio
E001	Ana Perez	F	19	Chihuahua	CETis 22	M101	Matemáticas Discretas	Matemáticas	Obligatoria	D001	Mario López	Maestría	10	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado	P2021
E002	Carlos Ruiz	M	20	Juárez	CBTis 128	M102	Programación I	Computación	Obligatoria	D002	Laura Gómez	Licenciatura	6	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado	P2021
E003	Diana Rios	F	21	Delicias	COBACH 3	M101	Matemáticas Discretas	Matemáticas	Obligatoria	D001	Mario López	Maestría	10	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado	P2021
E004	Erick Salas	M	22	Parral	CONALEP	M103	Física I	Ciencias	Obligatoria	D003	Juan Mendoza	Doctorado	15	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado	P2021

Parámetros de configuración del data warehouse.

Las herramientas que se han estado utilizando solamente ha sido Microsoft Excel, a continuación, se usaran dos herramientas Workbench SQL y Power BI.


Para identificar las tablas de hechos se utilizaron el siguiente esquema la cual nos ayuda a identificar la relación que tiene cada tabla.:



Además, pudimos realizar en Power BI la clasificación de los datos de la siguiente manera:

	A ^B _C id_estudiante	A ^B _C nombre_estudiante	A ^B _C sexo	1 ² ₃ edad	A ^B _C municipio	A ^B _C bachillerato_procedencia	A ^B _C id_materia	A ^B _C nombre_materia	A ^B _C area_conocimiento
1	E001	Ana Perez	F	19	Chihuahua	CETis 22	M101	Matemáticas Discretas	Matemáticas
2	E002	Carlos Ruiz	M	20	Juárez	CBTis 128	M102	Programación I	Computación
3	E003	Diana Ramos	F	21	Delicias	COBACH 3	M101	Matemáticas Discretas	Matemáticas
4	E004	Erick Salas	M	22	Parral	CONALEP	M103	Física I	Ciencias

Gracias a estos datos podemos responder varias preguntas, con el siguiente dashboard podemos obtener las respuestas:



Conclusión

Realizar este proyecto permitió organizar los datos para analizarlos de una forma más sencilla. Al limpiar la información, crear el Data Warehouse y elaborar el dashboard, fue posible responder las preguntas planteadas con mayor facilidad. Estos pasos ayudan a convertir muchos datos en información útil para tomar mejores decisiones dentro de una institución educativa.